一种基于强化学习的世界模型的自动驾驶规划方法

参考资料

- **核心思想来源:** Visual-RFT (相关链接已提供)
- **基础模型架构:** Drive-OccWorld (如论文 arXiv:2408.14197v3 所述)
- **撰写规范参考:** 《AI专利写作方法》文档 (隐式参考)
- **结构模板参考:** "一种基于强化学习和可验证奖励的三维目标检测优化方法" (已调整适配)
- gemini链接：https://aistudio.google.com/prompts/new_chat

技术背景详解

创新点对比阐述

1. 本发明要解决的技术问题是什么?

2. 为解决上述技术问题，本发明的创新点有哪些？创新点是如何解决上述技术问题的?

3. 与现有技术相比，本发明有何优点?

主要权利要求书

一种基于强化学习的世界模型的自动驾驶规划方法，其特征在于，包括以下步骤：
S1. 获取车辆周围环境的历史传感器观测数据；
S2. 将所述历史传感器观测数据输入基于强化学习的世界模型；所述世界模型处理所述历史传感器观测数据，并输出未来至少一个时间步的环境预测信息以及至少一条候选行车轨迹；所述环境预测信息包括环境占用状态和动态流信息；
S3. 基于所述环境预测信息和所述至少一条候选行车轨迹，选择得到最终行车轨迹；
S4. 根据所述最终行车轨迹控制车辆行驶。

附图说明

实施例一

为使本发明的目的、技术方案和优点更加清楚，下面将结合附图对本发明的实施方式作进一步地详细描述。应当理解，此处所描述的具体实施例仅用以解释本发明，并不用于限定本发明。

如图1所示，本实施例提供了一种基于强化学习的世界模型的自动驾驶规划方法，具体包括以下步骤：

步骤 S1：获取车辆周围环境的历史传感器观测数据。

在本实施例中，获取车辆周围环境的历史传感器观测数据包括但不限于：利用部署在车辆上的多个摄像头（例如前视、后视、左视、右视摄像头）采集在时间戳 $-h = -5$ 到 0 范围内的多帧图像数据，每帧时间间隔1s。可选地，也可以包含激光雷达（LiDAR）点云数据或其他类型传感器的数据。这些数据构成了对车辆行驶环境的连续观测记录 $o_{hist} = \{o_{-h}, \ldots, o_0\}$。

步骤 S2：将所述历史传感器观测数据输入基于强化学习的世界模型；所述世界模型处理所述历史传感器观测数据，并输出未来至少一个时间步的环境预测信息以及至少一条候选行车轨迹；所述环境预测信息包括环境占用状态和动态流信息。

备注：时间步长0.5s

在本实施例中，所使用的"基于强化学习的世界模型"是**预先训练优化好**的模块。其内部结构和训练过程如下所述：

(一) 世界模型结构（参考图2)

如图2所示，本实施例中基于强化学习的世界模型模型主要可以包括：

- **历史编码器 (History Encoder)：** 接收步骤 S1获取的历史传感器观测数据 o_{hist}（例如多视角图像序列），提取几何和语义特征，并将其转换为统一的鸟瞰视角（BEV）表示，输出历史BEV特征序列 F_{hist}^{bev}。例如，可以采用基于 Transformer 的 BEV 编码器（如 BEVFormer 或其变种）实现。
- **记忆与特征聚合模块 (Memory and Feature Aggregation Module)：** 接收历史BEV特征序列 F_{hist}^{bev}，聚合时序信息，并进行特征归一化以补偿动态变化和增强特征表达，输出聚合后的历史上下文特征 $F_{context}^{bev}$。

  备注：这里需要说明记忆与特征聚合模块具体是怎么实现的
- **世界模型解码器 (World Model Decoder)：** 这是一个自回归模块。它接收聚合后的历史上下文特征 $F_{context}^{bev}$ 和外部输入的动作条件 a_t（例如，规划速度、转向角、高级指令如“左转”或上一时刻规划的轨迹），预测未来时间步 $t+1$ 的 BEV 特征 F_{t+1}^{bev}。该过程可以表示为：$F_{t+1}^{bev} = W_D(F_{context}^{bev}, a_t)$。

  备注：这里需要说明世界模型解码器具体是怎么实现的
- **预测头 (Prediction Heads)：** 接收世界模型解码器输出的未来 BEV 特征 F_{t+1}^{bev}，并将其解码为具体的环境预测信息，包括未来环境的 3D 语义占用状态 S_{t+1} (哪些空间被占据以及被何种对象占据) 和 3D 动态流信息 F_{t+1} (描述物体运动速度和方向)。即：$(S_{t+1}, F_{t+1}) = \text{PredictionHeads}(F_{t+1}^{bev})$。
- **内部规划器 (Internal Planner)：** 基于预测头输出的未来环境占用状态 S_{t+1} 和动态流信息 F_{t+1}，并结合动作条件 a_t 或高级导航指令，生成至少一条候选行车轨迹 T_{cand}。此规划器在强化学习训练过程中被优化，以生成符合安全和任务要求的高质量轨迹。即：$T_{cand} = P(S_{t+1}, F_{t+1}, a_t)$ 或 $T_{cand} = P(S_{t+1}, F_{t+1}, \text{NavGoal})$。

  备注： 这里需要说明内部规划器具体是怎么实现的

(二) 世界模型优化过程（参考图3）

如图3所示，上述世界模型训练优化过程大致如下：

1. **数据准备：** 收集包含传感器数据（图像、点云等）和可能的车辆状态信息、专家驾驶轨迹或驾驶日志的自动驾驶数据集。

   备注：需要说明数据集数量有多少(比如10w帧)，数据集的标注具体标签是什么，实施例就是要给出具体实现方法
2. **模型初始化：** 构建具有上述结构（历史编码器、特征聚合、解码器、预测头、规划器）的世界模型，并使用预训练权重或随机初始化其参数 θ。同时，保留一个参数冻结的参考模型 π_{ref} (通常是优化开始前的模型或一个固定的行为克隆模型)。
3. **定义可验证奖励函数 (R_{verify})：** 设计一个或多个基于规则的奖励函数，用于直接评估模型生成的候选行车轨迹 T_{cand} 的质量。此奖励函数无需单独训练，而是根据预设规则（基于世界模型预测的 S_{t+1}, F_{t+1}）直接计算。例如，可以包括：
   - **碰撞奖励 $R_{collision}$:** 如果轨迹 T_{cand} 与世界模型预测的未来占用区域 S_{t+1} (特别是动态障碍物或静态障碍物区域)发生重叠，则给予较大的负奖励（惩罚）。
   - **越界奖励 $R_{offroad}$:** 如果轨迹 T_{cand} 超出预测的可行驶区域 (例如道路边界)，则给予负奖励。
   - **任务完成奖励 R_{goal}:** 如果轨迹有助于车辆遵循导航指令或达到目标状态（如跟车、变道、到达终点），则给予正奖励。
   - **平顺性/效率奖励 $R_{smooth/eff}$:** 对轨迹的曲率、加速度变化率、速度等进行评估，奖励平稳且高效的轨迹。
   - **总奖励：** 将上述各项奖励加权求和：
     $R_{verify}(T_{cand}|S_{t+1}, F_{t+1}) = w_1 R_{collision} + w_2 R_{offroad} + w_3 R_{goal} + w_4 R_{smooth/eff} + \ldots$，其中 w_i 为权重系数。

     备注：给出每个超参数具体的值，实施例要给出具体方法和参数。
4. **强化学习策略优化：**
   - 对于训练数据中的每个场景（输入历史观测数据 o_{hist} 和可选的动作条件 a_t），使用当前世界模型 π_θ生成 N 条候选行车轨迹 $\{T_{cand,1}, \ldots, T_{cand,N}\}$。模型同时预测环境 (S_{t+1}, F_{t+1})。
   - 利用步骤3中定义的**可验证奖励函数** R_{verify} 评估每条候选轨迹 $T_{cand,i}$，得到相应的奖励分数 $r_i = R_{verify}(T_{cand,i}|S_{t+1}, F_{t+1})$。
   - 采用强化学习策略优化算法（GRPO 的组相对策略优化）更新模型参数 θ。优化的目标是最大化期望奖励。更新过程通常会包含一个 KL 散度项，以限制 π_θ 与参考模型 π_{ref} 的差异，保证训练稳定性：
     $\theta_{new} \leftarrow \arg\max_\theta \mathbb{E}_{T\sim\pi_\theta(T|o_{hist},a_t)}[R_{verify}(T)] - \beta KL[\pi_\theta(T|o_{hist},a_t)||\pi_{ref}(T|o_{hist},a_t)]$
     其中 $\mathbb{E}$ 表示期望， $KL[\cdot||\cdot]$ 表示 KL 散度， β 是正则化系数。
5. **重复与收敛：** 重复步骤4，直到模型性能收敛，得到最终优化后的“基于强化学习的世界模型” (其参数为 θ^*)。

步骤 S3：基于所述环境预测信息和所述至少一条候选行车轨迹，选择得到最终行车轨迹。

在实际执行规划时，使用**已经优化好**的世界模型模。对于步骤 S2 输出的环境预测信息 S_{t+1}, F_{t+1} 和候选行车轨迹 T_{cand}（可能有多条），选择最终行车轨迹 T_{final}。这个选择过程可以基于：

- 直接选择候选轨迹中由内部规划器评估出的最优轨迹（其评估逻辑已在强化学习中通过 R_{verify} 优化）。

- 或者，可以有一个轻量级的最终选择器（可能是一个简单的规则集或小型评分网络），基于预测信息 (S_{t+1}, F_{t+1}) 和候选轨迹 T_{cand} 的安全性（例如，重新用 R_{verify} 或其简化版评分）、平顺性等指标，从候选轨迹中选择一条作为 T_{final}。

步骤 S4：根据所述最终行车轨迹控制车辆行驶。

将步骤 S3 得到的最终行车轨迹 T_{final}（通常是一系列未来时间点的期望位置、速度、姿态 (x_k, y_k, v_k, ψ_k)）转换为车辆底层控制器可以执行的指令，例如目标转向角 δ、加速度/减速度指令 a_{cmd}，从而控制车辆按照规划的轨迹行驶。

附图说明

- **图1：** 为本发明实施例提供的一种基于强化学习的世界模型的自动驾驶规划方法的流程示意图。
  - 图中示出了四个主要步骤框：S100 (获取历史数据 o_{hist}), S200 (世界模型处理与输出 $(S_{t+1}, F_{t+1}), T_{cand}$), S300 (选择最终轨迹 T_{final}), S400 (控制车辆)。箭头清晰地指示了从 S100 到 S400 的流程顺序。
- **图2：** 为本发明实施例中基于强化学习的世界模型模块 200 的结构示意图。
  - 图中示出了世界模型的主要组件框：历史编码器 210 (输入 o_{hist}，输出 F_{hist}^{bev}), 记忆与特征聚合模块 220 (输入 F_{hist}^{bev}，输出 $F_{context}^{bev}$), 世界模型解码器 230 (输入 $F_{context}^{bev}, a_t$，输出 F_{t+1}^{bev}), 预测头 240 (输入 F_{t+1}^{bev}，输出 S_{t+1}, F_{t+1}), 内部规划器 250 (输入 $S_{t+1}, F_{t+1}, a_t/\mathrm{NavGoal}$，输出 T_{cand})。箭头表示了模块间的数据流向。
- **图3：** 为本发明实施例中世界模型模块 200 的强化学习优化流程示意图。
  - 图中示出了训练过程的主要步骤框：数据准备 310, 模型初始化 320 (模型 π_θ, 参考模型 π_{ref}), 定义可验证奖励函数 R_{verify} 330, 强化学习策略优化 340 (内部可细化为：使用 π_θ 生成 (S_{t+1}, F_{t+1}) 和 T_{cand}, 使用 R_{verify} 评估得到 r_i, 根据奖励和 KL 散度更新 θ), 重复与收敛 350 (判断收敛，输出优化后的模型 θ^*)。箭头表示训练流程，其中步骤 340 到 350 之间存在循环。
- **图4（可选）：** 可验证奖励函数 R_{verify} 计算示意图。
  - 图中可以展示输入为预测的环境信息 (S_{t+1}, F_{t+1}) 和一条候选轨迹 $T_{cand,i}$，经过奖励计算模块（包含碰撞检测、越界判断、任务评估、平顺性评估等子模块），最终输出奖励分数 r_i 的过程。
- **图5（可选）：** BEV 特征或占用预测结果的可视化示例。
  - 图中可以展示一个具体的场景下，模型输出的鸟瞰视角（BEV）下的语义占用栅格图 S_{t+1}（用不同颜色表示不同类别如车辆、行人、可行驶区域等）和/或动态流 F_{t+1}（用箭头表示物体运动方向和速度）的可视化结果。

(修改版本二)一种基于强化学习的世界模型的自动驾驶规划方法

参考资料

- **核心思想来源:** Visual-RFT (相关链接已提供)
- **基础模型架构:** Drive-OccWorld (如论文 arXiv:2408.14197v3 所述)
- **撰写规范参考:** 《AI专利写作方法》文档 (隐式参考)
- **结构模板参考:** "一种基于强化学习和可验证奖励的三维目标检测优化方法" (已调整适配)
- gemini链接：https://aistudio.google.com/prompts/new_chat

技术背景详解

创新点对比阐述

1. 本发明要解决的技术问题是什么？

2. 为解决上述技术问题，本发明的创新点有哪些？创新点是如何解决上述技术问题的？

3. 与现有技术相比，本发明有何优点？

主要权利要求书

一种基于强化学习的世界模型的自动驾驶规划方法，其特征在于，包括以下步骤：
S1. 获取车辆周围环境的历史传感器观测数据；
S2. 将所述历史传感器观测数据输入基于强化学习的世界模型；所述世界模型处理所述历史传感器观测数据，并输出未来至少一个时间步的环境预测信息以及至少一条候选行车轨迹；所述环境预测信息包括环境占用状态和动态流信息；
S3. 基于所述环境预测信息和所述至少一条候选行车轨迹，选择得到最终行车轨迹；
S4. 根据所述最终行车轨迹控制车辆行驶。

附图说明

图1： 一种基于强化学习的世界模型的自动驾驶规划方法的流程示意图

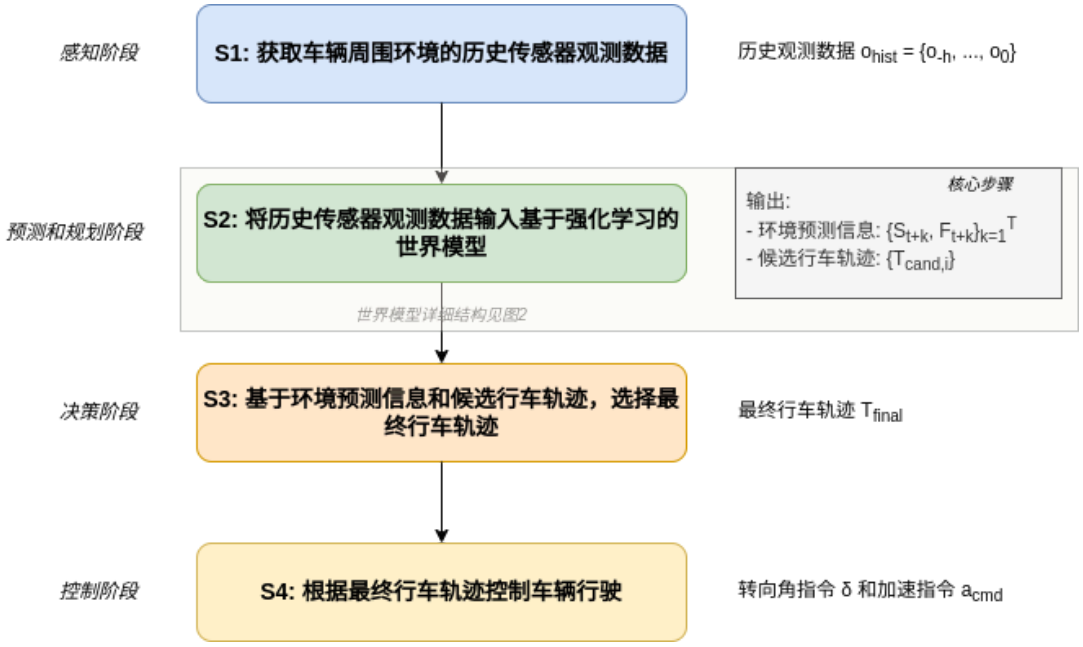


图2： 基于强化学习的世界模型模块的结构示意图

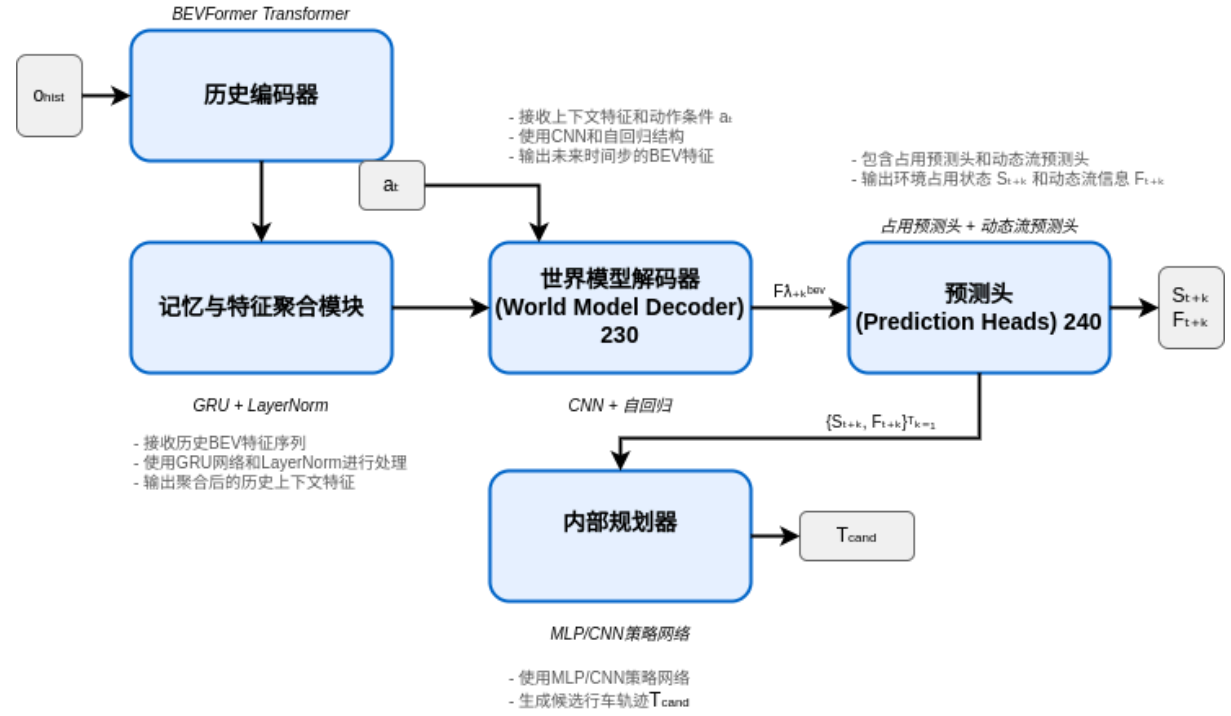
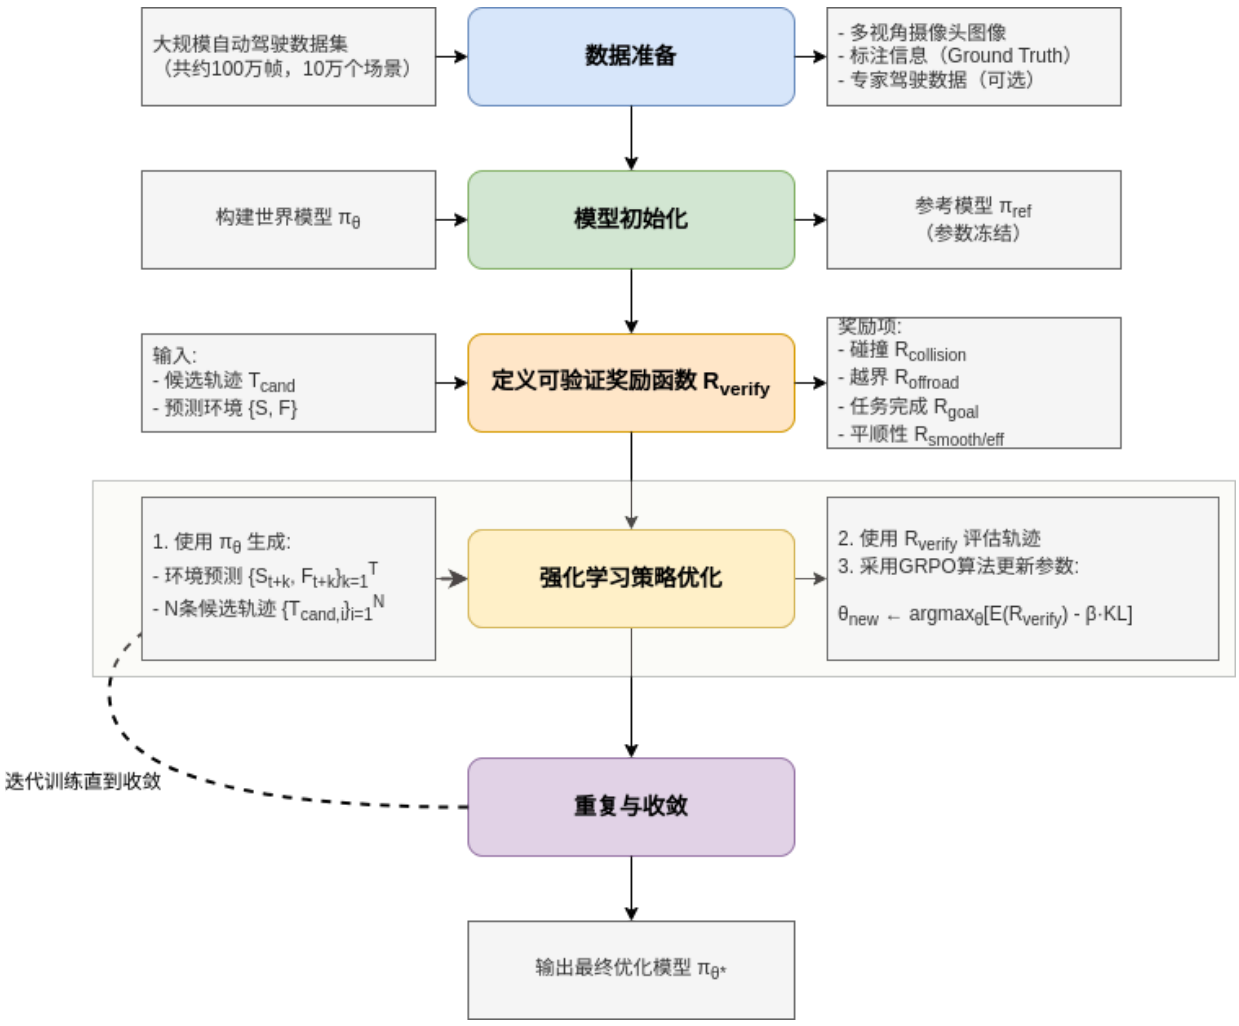


图3： 为世界模型模块的强化学习优化流程示意图



实施例一

为使本发明的目的、技术方案和优点更加清楚，下面将结合附图对本发明的实施方式作进一步地详细描述。应当理解，此处所描述的具体实施例仅用以解释本发明，并不用于限定本发明。

如图1所示，本实施例提供了一种基于强化学习的世界模型的自动驾驶规划方法，具体包括以下步骤：

步骤 S1：获取车辆周围环境的历史传感器观测数据。

在本实施例中，获取车辆周围环境的历史传感器观测数据包括但不限于：利用部署在车辆上的6个摄像头（例如，前视、后视、左前、右前、左后、右后摄像头）采集在时间戳 $-h = -5$ 秒到 0 秒范围内的多帧图像数据，每帧时间间隔为0.5秒，共计10帧。可选地，也可以包含激光雷达（LiDAR）点云数据、毫米波雷达数据或IMU（惯性测量单元）数据。这些数据构成了对车辆行驶环境的连续观测记录 $o_{hist} = \{o_{-h}, \ldots, o_0\}$。

步骤 S2：将所述历史传感器观测数据输入基于强化学习的世界模型；所述世界模型处理所述历史传感器观测数据，并输出未来至少一个时间步的环境预测信息以及至少一条候选行车轨迹；所述环境预测信息包括环境占用状态和动态流信息。

需要强调的是，在车辆实际运行时部署的"基于强化学习的世界模型"是依照下述训练优化过程预先训练好的模型。 以下描述包含了该模型的内部结构和训练优化方法，以便于理解其工作原理和获得方式。预测的时间步长在本实施例中设定为0.5秒，预测范围覆盖未来 $T = 5$ 秒（即10个时间步）。

(一) 世界模型结构（参考图2）

如图2所示，本实施例中基于强化学习的世界模型模型主要可以包括：

- **历史编码器 (History Encoder) 210：** 接收步骤 S1获取的历史传感器观测数据 o_{hist}（例如多视角图像序列），提取几何和语义特征。在本实施例中，采用类似于 BEVFormer 的架构，利用 Transformer 对多视角图像进行处理，生成统一的鸟瞰视角（BEV）表示，输出历史BEV特征序列 $F_{hist}^{bev} \in \mathbb{R}^{h \times H \times W \times C}$，其中 h 是历史时间步数量， H, W 是 BEV 网格的高度和宽度， C 是特征通道数。
- **记忆与特征聚合模块 (Memory and Feature Aggregation Module) 220：** 接收历史BEV特征序列 F_{hist}^{bev}。在本实施例中，该模块采用**门控循环单元 (Gated Recurrent Unit, GRU)** 网络来沿时间维度处理 F_{hist}^{bev}，有效聚合时序信息并捕捉动态变化。GRU 的输出随后通过**层归一化 (Layer Normalization)** 进行处理，以增强特征表达的稳定性，最终输出聚合后的历史上下文特征 $F_{context}^{bev} \in \mathbb{R}^{H \times W \times C'}$。
- **世界模型解码器 (World Model Decoder) 230：** 这是一个自回归模块。它接收聚合后的历史上下文特征 $F_{context}^{bev}$ 和外部输入的动作条件 a_t。在本实施例中，动作条件 a_t（例如，目标速度和曲率）首先被编码为一个向量，然后扩展（broadcast）并与 $F_{context}^{bev}$ 在通道维度上拼接（concatenate）。该拼接后的特征被输入到一个**卷积神经网络 (Convolutional Neural Network, CNN)**，该 CNN 预测下一个时间步 $t+1$ 的 BEV 特征 F_{t+1}^{bev}。该过程可以表示为：$F_{t+1}^{bev} = \mathrm{CNN}(\mathrm{concat}(F_{context}^{bev}, \mathrm{encode}(a_t)))$。解码器按时间步循环调用，以预测未来多个时间步的 BEV 特征序列 $\{F_1^{bev}, \ldots, F_T^{bev}\}$。
- **预测头 (Prediction Heads) 240：** 接收世界模型解码器输出的未来各个时间步的 BEV 特征 F_{t+k}^{bev} ($k = 1, \ldots, T$)，并将其解码为具体的环境预测信息。在本实施例中，包括两个并行的预测头：
  - **占用预测头:** 一个基于 CNN 的分割头，输出未来环境的 3D 语义占用状态 S_{t+k}，例如，在 BEV 网格上预测每个栅格属于{可行驶区域、静态障碍物（建筑、路沿）、动态障碍物（车辆、行人）、未知}等类别的概率。
  - **动态流预测头:** 一个基于 CNN 的回归头，输出 3D 动态流信息 F_{t+k}，例如，在 BEV 网格上预测每个动态障碍物栅格的未来速度向量 (v_x, v_y) 。
    即：$(S_{t+k}, F_{t+k}) = \mathrm{PredictionHeads}(F_{t+k}^{bev})$ for $k = 1, \ldots, T$.
- **内部规划器 (Internal Planner) 250：** 基于预测头输出的**整个预测时域**内的环境信息 $\{(S_{t+k}, F_{t+k})\}_{k=1}^{T}$，并结合动作条件 a_t 或高级导航指令（NavGoal），生成至少一条候选行车轨迹 T_{cand}。在本实施例中，内部规划器实现为一个**多层感知机 (Multi-Layer Perceptron, MLP)** 或基于 CNN 的策略网络。该网络将预测的环境信息（例如，将 S 和 F 序列编码为一个综合状态表示）和目标信息（例如，目标点、目标速度、路线指令）作为输入，输出定义候选轨迹的参数（例如，未来一系列路径点 (x_k, y_k) 或多项式曲线系数）。为了生成多条候选轨迹，可以采用**在策略网络的输出层引入随机性采样**（例如，从高斯分布采样）或**集束搜索 (Beam Search)** 等方法，生成 N 条不同的高质量候选轨迹 $\{T_{cand,1}, \ldots, T_{cand,N}\}$。此规划器在强化学习训练过程中被共同优化。

(二) 世界模型优化过程（参考图3）

如图3所示，上述世界模型训练优化过程大致如下：

1. **数据准备 310：** 收集大规模、多样化的自动驾驶数据集。例如，使用包含约 **100 万帧**行驶数据的 nuScenes 或 Waymo Open Dataset 的子集，这些数据覆盖了各种城市和高速公路场景，总计约 **10 万个**不同的驾驶片段/场景。数据集需包含：
   - 时间同步的多视角摄像头图像。
   - 可选的 LiDAR 点云数据。
   - 车辆自身的姿态、速度、加速度等状态信息 (Ego-vehicle state)。
   - **标注信息（Ground Truth Labels）：** 用于监督训练预测头所需的真值标签，包括：

        - **3D 目标检测与跟踪：** 动态物体（车辆、行人、自行车等）的 3D 边界框、类别和唯一跟踪 ID。
        - **3D 语义地图分割：** 静态环境元素（如可行驶区域、人行道、建筑物、植被等）的体素级或 BEV 级语义标签。
    - **专家驾驶数据（可选）：** 人类驾驶员的操作记录或高质量的参考轨迹，可用于模型的预训练或作为强化学习中的参考策略。
2. **模型初始化 320：** 构建具有上述结构（历史编码器 210、特征聚合 220、解码器 230、预测头 240、规划器 250）的世界模型 π_θ，并使用预训练权重（例如，从图像或 BEV 感知任务预训练的模型加载部分权重）或随机初始化其参数 θ。同时，保留一个参数冻结的参考模型 π_{ref} (例如，使用行为克隆预训练后的模型或优化初期阶段的模型)。
3. **定义可验证奖励函数 (R_{verify}) 330：** 设计一个基于规则的奖励函数，用于直接评估模型生成的候选行车轨迹 T_{cand} 的质量。此奖励函数基于世界模型**自己预测**的未来环境状态 $(S_{t+k}, F_{t+k})_{k=1}^{T}$ 进行计算，无需额外标注或模型。**以下为本实施例中使用的奖励项及其示例权重（注意：这些权重为示例值，实际应用中需要根据实验效果精细调整）：**
    - **碰撞奖励 $R_{collision}$:** 如果轨迹 T_{cand} 在预测时域内任何时刻 $t+k$ 与预测的动态障碍物占用区域或静态障碍物占用区域 S_{t+k} 发生重叠，则给予一个较大的负奖励。例如，设定为 -100。
    - **越界奖励 $R_{offroad}$:** 如果轨迹 T_{cand} 在预测时域内任何时刻 $t+k$ 超出预测的可行驶区域 S_{t+k}，则给予负奖励。例如，设定为 -50。
    - **任务完成奖励 R_{goal}:** 根据轨迹是否遵循导航指令（如保持车道、执行变道、朝向目标点前进）给予正奖励。例如，轨迹终点与目标点的距离越近，奖励越高，最高可达 +50；或者根据导航任务（如成功完成一次变道）给予阶段性奖励 +20。
    - **平顺性/效率奖励 $R_{smooth/eff}$:** 对轨迹的舒适性和效率进行评估。例如：
        - 惩罚过大的纵向加速度/减速度变化（Jerk）：$R_{jerk} = -0.1 \times \sum jerk_k^2$。
        - 惩罚过大的横向加速度：$R_{lat_accel} = -0.5 \times \sum lat_accel_k^2$。
        - 奖励接近目标速度行驶：$R_{speed} = +0.2 \times \sum(1 - |v_k - v_{target}|/v_{target})$（仅当 $v_k < v_{target}$ 时）。
    - **总奖励：** 将上述各项奖励加权求和得到最终的可验证奖励 R_{verify}。本实施例中，采用以下示例权重（w_i）：
      $R_{verify}(T_{cand}|\{S_{t+k}, F_{t+k}\}_{k=1}^{T}) = w_{collision}R_{collision} + w_{offroad}R_{offroad} + w_{goal}R_{goal} + w_{jerk}R_{jerk} + w_{lat_accel}R_{lat_accel} + w_{speed}R_{}$
      其中，**示例权重为：** $w_{collision} = 1.0, w_{offroad} = 1.0, w_{goal} = 0.8, w_{jerk} = 1.0, w_{lat_accel} = 1.0, w_{speed} = 0.5$。这些权重需要通过实验仔细调整以平衡不同目标（安全、任务、舒适度）。
4. **强化学习策略优化 340：**
    - 对于训练数据中的每个场景（输入历史观测数据 o_{hist} 和可选的动作条件 a_t 或导航目标 NavGoal），使用当前世界模型 π_θ 预测未来环境 $(\{S_{t+k}, F_{t+k}\}_{k=1}^{T})$，并生成 N 条候选行车轨迹 $\{T_{cand,1}, \ldots, T_{cand,N}\}$（例如 $N = 16$）。
    - 利用步骤 3 中定义的**可验证奖励函数 R_{verify}** 评估每条候选轨迹 $T_{cand,i}$，得到相应的奖励分数 $r_i = R_{verify}(T_{cand,i}|\{S_{t+k}, F_{t+k}\}_{k=1}^{T})$。
    - 采用**组相对策略优化 (Group Relative Policy Optimization, GRPO)** 算法更新模型参数 θ（包括解码器、预测头和内部规划器的参数，历史编码器和聚合模块通常也一起微调）。GRPO 旨在最大化轨迹的期望奖励，同时通过 KL 散度项约束当前策略 π_θ 与参考策略 π_{ref} 的偏差，以稳定训练过程。优化目标函数形式如下：
      $\theta_{new} \leftarrow \arg\max_\theta \mathbb{E}_{T\sim\pi_\theta(T|o_{hist},a_t)}[R_{verify}(T)] - \beta KL[\pi_\theta(T|o_{hist},a_t)||\pi_{ref}(T|o_{hist},a_t)]$
      其中 $\mathbb{E}$ 表示期望，$KL[\cdot||\cdot]$ 表示 KL 散度。在本实施例中，正则化系数 β **设定为 0.1**。GRPO 的具体实现涉及计算优势函数和执行策略梯度更新，通常基于采样得到的 N 条轨迹及其奖励。
5. **重复与收敛 350：** 重复步骤 4 的策略优化过程，在整个数据集上进行多轮迭代（epochs），直到模型的性能（例如，在验证集上的平均奖励、碰撞率、任务成功率等指标）收敛或达到预设的训练步数，得到最终优化后的“基于强化学习的世界模型” (其参数为 θ^*)。

步骤 S3：基于所述环境预测信息和所述至少一条候选行车轨迹，选择得到最终行车轨迹。

在实际执行规划时（即车辆运行时），使用**已经通过上述步骤优化好的**世界模型 π_{θ^*}。对于输入的实时历史传感器数据 o_{hist}，模型执行一次前向传播（步骤 S2），输出未来环境预测信息 $\{S_{t+k}, F_{t+k}\}_{k=1}^{T}$ 和 N 条候选行车轨迹 $\{T_{cand,1}, \ldots, T_{cand,N}\}$。
选择最终行车轨迹 T_{final} 的过程如下：

- 首先，使用预定义的硬性安全规则（例如，检查是否有任何轨迹点与高置信度的近期障碍物预测发生碰撞）过滤掉明显不安全的候选轨迹。
- 然后，对于剩余的候选轨迹，再次使用（或使用其简化版本）**可验证奖励函数 R_{verify}** 对它们进行评分。
- 选择得分最高的候选轨迹作为最终行车轨迹 T_{final}。

步骤 S4：根据所述最终行车轨迹控制车辆行驶。

将步骤 S3 得到的最终行车轨迹 T_{final}（该轨迹通常表示为未来若干秒内，每隔一个短时间步长（例如 0.5 秒）的期望车辆状态序列，包括位置 (x_k, y_k)、朝向 ψ_k、速度 v_k 等）输入给车辆的底层运动控制器。该控制器（例如，一个模型预测控制（MPC）控制器或 PID 控制器）根据当前的车辆状态和 T_{final}，计算出实际的转向角指令 δ 和油门/刹车指令 a_{cmd}，以驱动车辆尽可能精确地沿着 T_{final} 行驶。

附图说明

- **图1：** 为本发明实施例提供的一种基于强化学习的世界模型的自动驾驶规划方法的**流程示意图**。
  - 图中示出了四个主要步骤框：S100 (获取历史数据 o_{hist}), S200 (世界模型处理，输出环境预测 $\{S_{t+k}, F_{t+k}\}_{k=1}^{T}$ 和候选轨迹 T_{cand}), S300 (基于预测和候选轨迹选择最终轨迹 T_{final}), S400 (根据最终轨迹控制车辆)。箭头清晰地指示了从 S100 到 S400 的信息流和控制流。
- **图2：** 为本发明实施例中步骤 S200 使用的**基于强化学习的世界模型模块的结构示意图**。
  - 图中示出了世界模型的主要组件框：历史编码器 210 (例如基于 Transformer 的 BEV 编码器，输入 o_{hist}，输出 F_{hist}^{bev}), 记忆与特征聚合模块 220 (例如 GRU 网络 + LayerNorm，输入 F_{hist}^{bev}，输出 $F_{context}^{bev}$), 世界模型解码器 230 (例如基于 CNN 的自回归模块，输入 $F_{context}^{bev}, a_t$，输出未来 BEV 特征 F_{t+k}^{bev}), 预测头 240 (例如并行的 CNN 分割头和回归头，输入 F_{t+k}^{bev}，输出占用 S_{t+k} 和流 F_{t+k}), 内部规划器 250 (例如 MLP 或 CNN 策略网络，输入 $\{S, F\}_{k=1}^{T}, a_t/\mathrm{NavGoal}$，输出 N 条候选轨迹 T_{cand})。箭头表示了模块间的数据流向。
- **图3：** 为本发明实施例中**世界模型模块的强化学习优化流程示意图**。
  - 图中示出了训练过程的主要环节：数据准备 310 (标注数据和专家数据), 模型初始化 320 (构建模型 π_θ 和参考模型 π_{ref}), 定义可验证奖励函数 R_{verify} 330 (基于规则，输入 $T_{cand}, \{S, F\}$，输出奖励 r), 强化学习策略优化 340 (循环核心：使用 π_θ 生成预测和轨迹，使用 R_{verify} 评估，利用 GRPO 算法和 KL 散度约束更新 θ)，以及重复与收敛 350 (判断训练结束条件，输出最终优化模型 θ^*)。箭头表示训练流程，特别是指出了从 340 到 350 的迭代循环。